

Detekcja cofniętej linii włosów przy użyciu metod przetwarzania obrazów i sieci CNN

Karolina Sawicka, IAD, Id. 102994

Wstęp i cel projektu

Współczesna analiza obrazu twarzy (ang. *Facial Attribute Analysis*) jest jedną z najdynamiczniej rozwijających się dziedzin widzenia komputerowego. Znajduje ona zastosowanie nie tylko w systemach biometrycznych, ale także w medycynie estetycznej, kryminalistyce oraz wirtualnej rzeczywistości. Niniejszy projekt skupia się na problemie detekcji cofającej się linii włosów (atrybut *Receding Hairline*), który jest cechą szczególnie wymagającą dla algorytmów klasycznych ze względu na dużą zmienność fryzur, oświetlenia oraz występowanie okluzji (np. nakryć głowy). Dla uproszczenia opisu oraz poprawy czytelności raportu, w dalszej części pracy termin “zakola” będzie używany jako bezpośredni synonim dla analizowanego atrybutu “cofnięta linia włosów”.

Do realizacji projektu wykorzystano zbiór danych *CelebFaces Attributes Dataset (CelebA)*. Jest to wielkoskalowy zbiór zawierający ponad 200 000 obrazów twarzy celebrytów, z których każdy opatrzony jest 40 binarnymi atrybutami. Wybór tego zbioru podyktowany był jego wysoką jakością oraz różnorodnością, co pozwala na trenowanie zaawansowanych modeli głębokiego uczenia.

Głównym celem projektu jest opracowanie i implementacja systemu automatycznej klasyfikacji obrazów twarzy pod kątem występowania zakoli, przy wykorzystaniu i porównaniu metod klasycznego przetwarzania obrazu oraz głębokich sieci neuronowych.

Projekt został udostępniony na platformie GitHub <https://github.com/carolynee01/receding-hairline>.

Szczegółowy opis realizacji etapów projektu

Konfiguracja środowiska i zapewnienie reprodukowalności

Pierwszym i kluczowym krokiem w procesie badawczym było zapewnienie determinizmu obliczeń. W uczeniu maszynowym wiele procesów (inicjalizacja wag sieci, tasowanie danych, podział na zbiory) odbywa się w sposób losowy.

Zastosowano stałą wartość ziarna losowości dla trzech głównych bibliotek: **random**, **numpy** oraz **tensorflow**. Ustalenie stałego ziarna pozwala na uzyskanie identycznych wyników przy każdym uruchomieniu skryptu. Jest to niezbędne do poprawnej weryfikacji modelu przez osoby trzecie oraz do rzetelnego porównywania wpływu zmian w architekturze sieci na jej końcową skuteczność.

Akwizycja danych: Zbiór CelebA

Do realizacji zadania wykorzystano zbiór danych *CelebA*, pobrany za pomocą biblioteki **kagglehub**. Wykorzystano plik `list_attr_celeba.csv`, zawierający binarną adnotację cech twarzy. Skupiono się na atrybucie `Receding_Hairline` (cofnięta linia włosów/zakola).

Selekcja i balansowanie zbioru danych

Oryginalny zbiór CelebA charakteryzuje się dużym niezbalansowaniem (znacznie więcej osób posiada pełną linię włosów niż zakola). Praca na takim zbiorze mogłaby doprowadzić do zjawiska, w którym model uczy się “zgadywania” klasy większościowej, zamiast rozpoznawania cech.

Zastosowano technikę undersamplingu klasy większościowej. Wyselekcjonowano dokładnie 5000 zdjęć dla klasy “Zakola” (etykieta 1) oraz 5000 zdjęć dla klasy “Brak zakoli” (etykieta -1 w CSV). Stworzenie zbalansowanego zbioru o proporcji 1:1 jest krytyczne dla poprawnego wyznaczenia metryk takich jak *Accuracy* czy *F1-score*. Przy zbalansowanych klasach wynik 50% oznacza losowy wybór, a każdy wynik powyżej tej wartości realnie odzwierciedla zdolności predykcyjne modelu.

Wstępne przetwarzanie obrazu i analiza dyskretyzacji obrazu

Proces przygotowania pojedynczego obrazu do analizy obejmuje trzy główne kroki techniczne: akwizycję, transformację geometryczną oraz konwersję barwną.

Opis techniczny operacji:

1. **Akwizycja i obsługa ścieżek:** Ze względu na specyficzną strukturę folderów biblioteki `kagglehub`, zastosowano dynamiczne budowanie ścieżek przy użyciu `os.path.join`. Zapewnia to przenośność kodu między różnymi systemami operacyjnymi.
2. **Skalowanie (Resizing):** Każdy obraz wejściowy jest transformowany do stałego rozmiaru 128×128 pikseli przy użyciu funkcji `cv2.resize`.


Większość algorytmów uczenia maszynowego (w tym planowana sieć CNN oraz deskryptor HOG) wymaga wejścia o stałych wymiarach. Rozmiar 128×128 zachowuje wystarczającą liczbę detali pozwalającą dostrzec linię włosów, jednocześnie znacząco redukując zapotrzebowanie na pamięć RAM i przyspieszając proces trenowania modelu.

3. **Konwersja do skali szarości:** Obraz w formacie BGR (standard OpenCV) jest przekształcany na 8-bitową skalę szarości (`cv2.COLOR_BGR2GRAY`).

W wykrywaniu krawędzi i konturów (co jest kluczowe przy zakolach) najważniejsza jest informacja o natężeniu jasności (gradientach), a nie o konkretnym odcieniu skóry czy koloru włosów. Skala szarości pozwala algorytmom skupić się na strukturze geometrycznej twarzy.

Analiza na przykładzie

Wstępnym etapem prac było poprawne wczytanie obrazu testowego ze zbioru CelebA oraz przygotowanie potoku przetwarzania, który pozwoli na demonstrację kluczowych parametrów obrazu cyfrowego.



Konwersja przestrzeni barwnych

Obraz wejściowy w formacie BGR został przekonwertowany do trzech standardowych przestrzeni: RGB (używanej do poprawnej wizualizacji), Skali szarości (wykorzystywanej w dalszej analizie krawędzi) oraz *HSV* (*Hue*, *Saturation*, *Value*). Wybór przestrzeni HSV jest strategiczny dla późniejszych etapów segmentacji, ponieważ pozwala ona na oddzielenie informacji o kolorze skóry od jej jasności, co czyni algorytmy odporniejszymi na cienie.

Dyskretyzacja przestrzenna (próbkiowanie)

W celu zbadania wpływu rozdzielczości na czytelność cech twarzy, przeprowadzono proces próbkiowania w dół. Przy zastosowaniu współczynnika próbkiowania równego 4, rozdzielczość obrazu uległa drastycznemu zmniejszeniu (z poziomu 178×218 do zaledwie 45×55 pikseli).

Na załączonej wizualizacji ogólny kształt głowy pozostaje widoczny, subtelne detale, takie jak precyzyjna linia zakoli, ulegają zatarciu. To doświadczenie pozwoliło ustalić docelową rozdzielczość modelu (128×128) jako bezpieczny kompromis.

Dyskretyzacja jasności (kwantyzacja)


Kolejnym krokiem była redukcja liczby poziomów jasności z 256 (standardowe 8 bitów) do zaledwie **4 poziomów** (2 bity). Operację tę wykonano poprzez matematyczne zmapowanie intensywności pikseli za pomocą dzielenia całkowitego.

Pozwoliło to na zaobserwowanie utraty subtelnych przejść tonalnych, co w kontekście detekcji linii włosów może prowadzić do uproszczenia krawędzi, ale również do usunięcia szumu w ciemnych obszarach.

Analiza histogramów

Dopełnieniem analizy jest porównanie histogramów przed i po kwantyzacji:

1. **Histogram 8-bitowy:** przedstawia ciągły (gęsty) rozkład natężenia pikseli w całym zakresie od 0 do ok. 235. Widoczne są charakterystyczne wzniesienia odpowiadające jasnej karnacji skóry oraz tłu.
2. **Histogram po kwantyzacji:** wykres zmienił się w zbiór czterech odizolowanych słupków (tzw. prążków). Każdy piksel z oryginalnego obrazu został przypisany do jednej z czterech “koszyk” jasności. Ta wizualizacja matematycznie potwierdza poprawność przeprowadzonej kwantyzacji i obrazuje utratę informacji o subtelnych detalach tekstury.



Filtracja splotowa i segmentacja obrazu

W tej części projektu poddano analizie wpływ różnych filtrów dolno- i górnoprzepustowych na czytelność cech twarzy oraz przetestowano techniki binaryzacji.



Zastosowano dwa rodzaje filtrów wygładzających: **filtr Gaussa** oraz **filtr medianowy**:

- **Filtr Gaussa:** wykorzystuje jądro o rozmiarze 5×5 do rozmycia obrazu. Operacja ta pozwala na usunięcie drobnych zakłóceń i tekstur, które mogłyby generować fałszywe krawędzie w kolejnych krokach. Na wizualizacji obraz stał się bardziej “miękki”, co przygotowuje go do skuteczniejszej detekcji konturów.
- **Filtr medianowy:** skutecznie eliminuje szum typu “sól i pieprz”, zachowując jednocześnie relatywnie ostre krawędzie obiektów, co jest przewagą nad rozmyciem gaussowskim.

Filtr Sobela jest operatorem różniczkowym, który oblicza przybliżenie gradientu natężenia jasności obrazu. W kodzie skupiono się na gradiencie poziomym ($dx = 1$), co pozwoliło na uwypuklenie pionowych i skośnych

krawędzi twarzy. Na otrzymanym obrazie krawędziowym najwyższy kontrast uzyskano na styku czoła i linii włosów oraz w okolicach małżowin usznych. Jest to kluczowa informacja dla modelu, ponieważ precyzyjnie definiuje obszar, w którym występuje cofnięta linia włosów.

Przetestowano dwie techniki zamiany obrazu w skali szarości na obraz binarny (czarno-biały):

1. **Progowanie globalne** - zastosowano sztywny próg jasności na poziomie 127. Jak widać na wynikach, metoda ta jest wysoce zawodna przy oświetleniu nierównomiernym – znaczna część twarzy została “wypalona” (zmieniona w białą plamę), co uniemożliwia analizę linii włosów po lewej stronie zdjęcia.
2. **Progowanie adaptacyjne** - w tej metodzie próg jest obliczany lokalnie dla każdego piksela na podstawie jego sąsiedztwa.

Progowanie adaptacyjne pozwoliło na wydobywanie zarysu twarzy i fryzury nawet w obszarach zacienionych. Na wizualizacji widać granicę między czołem a owłosieniem skóry głowy, co czyni tę metodę znacznie bardziej użyteczną w kontekście automatycznej segmentacji czoła.

Wybór filtracji przed analizą krawędzi jest podyktowany koniecznością usunięcia artefaktów kompresji JPG typowych dla zbioru CelebA. Zastosowanie filtra Sobela z jądrem 5×5 zamiast standardowego 3×3 pozwoliło na uzyskanie grubszych, bardziej ciągłych krawędzi, co jest korzystne dla późniejszego etapu wyznaczania parametrów geometrycznych.

Segmentacja i pomiary geometryczne

Etap ten miał na celu wyodrębnienie obszaru badawczego i matematyczne opisanie cech geometrycznych twarzy. Choć zaimplementowany potok przetwarzania – obejmujący filtrację Gaussa, konwersję do przestrzeni HSV, maskowanie koloru skóry oraz operacje morfologiczne – pozwolił na poprawną segmentację największego obszaru skóry, przeprowadzone testy wykazały niską skuteczność tej metody w kontekście bezpośredniego wykrywania zakoli.

Głównym problemem zaimplementowanego algorytmu jest brak precyzyjnej lokalizacji regionu zainteresowania (Region of Interest – ROI). Metoda oparta na wykrywaniu konturów na masce binarnej izoluje **całą powierzchnię twarzy**, a nie tylko czoło. W rezultacie obliczane parametry, takie jak pole powierzchni (*Area*) czy obwód (*Perimeter*), są silnie determinowane przez czynniki niezwiązane z linią włosów, takie jak:

- **obecność zarostu** - broda i wąsy drastycznie zmieniają dolny kontur maski, co fałszuje wyniki pomiarów geometrycznych.
- **kształt szczęki** - różnice anatomiczne w budowie żuchwy wpływają na pole powierzchni bardziej niż stopień cofnięcia linii włosów.
- **fryzura**: - w przypadku kobiet lub mężczyzn z długimi włosami, segmentacja koloru skóry często “wycieka” poza czoło lub jest przez włosy nienaturalnie ograniczana.

Kolejnym czynnikiem obniżającym wiarygodność tej metody jest brak normalizacji. Pole powierzchni wyrażone w pikselach jest zależne od odległości twarzy od obiektywu i rozdzielczości zdjęcia. Bez odniesienia pola czoła do całkowitej powierzchni twarzy (np. poprzez wykrycie punktów charakterystycznych – *Facial Landmarks*), otrzymane liczby mają niską wartość diagnostyczną.

Wizualizacja wyników potwierdza te obawy: na wielu zdjęciach czerwony kontur poprawnie opasuje twarz, ale różnice w wartościach *Area* między klasą „Zakola” a „Brak” są statystycznie niejednoznaczne i często wynikają z kadrowania zdjęcia, a nie z cech fizjonomicznych.

Metoda segmentacji geometrycznej okazała się nieskuteczna w procesie klasyfikacji atrybutu *Receding Hairline*. Potwierdza to zasadność przejścia do metod głębokiego uczenia. Sieci konwolucyjne (CNN), w przeciwieństwie do prostych pomiarów pola powierzchni, są w stanie samodzielnie zidentyfikować istotne cechy teksturalne i krawędziowe w górnej części twarzy, ignorując nieistotne matematycznie obszary brody czy policzków.

Klasa: Zakola
Area: 11478.0



Klasa: Brak
Area: 31674.0




Ekstrakcja cech metodami klasycznymi i analiza skupisk

W tej części projektu porzucono zawodną metodę segmentacji koloru skóry na rzecz deskryptora **HOG** (*Histogram of Oriented Gradients*), który jest standardem w zadaniach detekcji obiektów o stałej strukturze (np. twarze, sylwetki ludzi).

Algorytm HOG działa poprzez obliczanie rozkładu kierunków gradientów w małych fragmentach obrazu (komórkach). Dla potrzeb projektu obrazy o rozmiarze 128×128 zostały podzielone na komórki 16×16 pikseli, co pozwoliło na uchwycenie lokalnych zmian krawędzi linii włosów przy jednoczesnej odporności na drobne przesunięcia twarzy w kadrze. Przed przystąpieniem do analizy, wektory cech zostały poddane standaryzacji przy użyciu **StandardScaler**. Jest to krok niezbędny, aby każda cecha miała średnią 0 i odchylenie standardowe 1, co zapobiega dominacji algorytmu przez cechy o większych zakresach wartości liczbowych.

Ze względu na to, że deskryptor HOG generuje wektor o bardzo dużej liczbie wymiarów, zastosowano metodę PCA (*Principal Component Analysis* – Analiza Głównych Składowych), aby zredukować wymiarowość danych do dwóch składowych głównych. Pozwoliło to na stworzenie dwuwymiarowego wykresu skupisk (scatter plot).

Na załączonej wizualizacji widać znaczące nałożenie się (overlapping) obu klas. Punkty niebieskie (Brak) i czerwone (Tak) tworzą jedną dużą chmurę, w której trudno wyznaczyć wyraźną granicę separacji.



Fakt, że klasy nie tworzą oddzielnych skupisk w przestrzeni PCA, sugeruje, że cechy HOG – mimo że są znacznie bardziej zaawansowane niż proste pole powierzchni – nadal nie wyodrębniają wystarczająco unikalnych wzorców dla atrybutu zakoli. Jest to bezpośredni sygnał, że klasyfikatory liniowe będą miały trudności z uzyskaniem wysokiej precyzji.

W celu weryfikacji skuteczności cech HOG przetestowano dwa popularne modele: **SVM** (*Support Vector Machine*) z jądrem liniowym oraz **k-NN** (*k-Nearest Neighbors*). Wyniki prezentują się następująco:

- **Skuteczność SVM: 66,75%**
- **Skuteczność k-NN: 67,75%**

Uzyskana dokładność na poziomie ok. **67%** jest wynikiem znacznie lepszym niż losowe zgadywanie, co dowodzi, że analiza gradientów faktycznie niesie informacje o linii włosów. Niemniej jednak, wynik ten jest nadal zbyt niski dla profesjonalnych zastosowań.

Analiza wykazała, że klasyczne podejście HOG napotyka na barierę skuteczności, której nie da się przebić bez bardziej złożonych modeli. Duży stopień wymieszania klas na wykresie PCA oraz relatywnie niska skuteczność klasyfikatorów ostatecznie potwierdzają konieczność zastosowania głębokich sieci neuronowych, które są w stanie samodzielnie wyuczyć się nieliniowych relacji między pikselami.

Klasyfikacja obrazów z wykorzystaniem głębokich sieci konwolucyjnych

Realizacja tego etapu polegała na stworzeniu nowoczesnego modelu sztucznej inteligencji, który potrafi samodzielnie uczyć się rozpoznawania cech twarzy bezpośrednio ze zdjęć.

Aby wyniki były rzetelne, zbiór danych podzielono na trzy części: treningową (70%), walidacyjną (15%) oraz testową (15%). Zadbano o to, by w każdej z nich znajdowała się taka sama liczba przykładów osób

z zakolami i bez nich. Zapobiegło to sytuacji, w której model mógłby “zgadywać” najczęściej występujący wynik zamiast faktycznie analizować zdjęcie.

W celu zwiększenia skuteczności modelu zastosowano tzw. augmentację. Podczas nauki system otrzymywał zdjęcia lekko zmodyfikowane – obrócone, przesunięte lub o zmienionej jasności. Symuluje to naturalne różnice w zdjęciach (różne kąty nachylenia głowy czy oświetlenie) i zmusza model do szukania istotnych cech, a nie uczenia się obrazów na pamięć.

Zaprojektowano strukturę składającą się z kilku warstw, które działają jak “filtry” wylapujące wzorce – od prostych krawędzi po skomplikowane kształty linii włosów. Dodatkowo zastosowano mechanizm (Dropout), który podczas nauki losowo wyłącza część połączeń, co uodparnia model na błędy i sprawia, że lepiej radzi sobie z nowymi, nieznanymi wcześniej zdjęciami.


Proces uczenia trwał 15 cykli (epok). Ostatecznie model uzyskał skuteczność na poziomie 84,3%. Jest to wynik o ponad 16 punktów procentowych lepszy niż w przypadku metod klasycznych. Wysoka skuteczność potwierdza, że sieci neuronowe znacznie lepiej radzą sobie z analizą tak złożonych cech ludzkiej twarzy jak zakola, ponieważ potrafią zignorować nieistotne szczegóły (np. tło czy oświetlenie) na rzecz istotnych kształtów anatomicznych.

Ewaluacja i analiza wyników modelu CNN


Finalna weryfikacja modelu została przeprowadzona na zbalansowanym zbiorze testowym liczącym 1500 obrazów, co pozwoliło na rzetelną ocenę zdolności sieci do generalizacji. Uzyskana dokładność na poziomie **84%** świadczy o wysokiej stabilności systemu, a niemal identyczne wartości precyzji i pełności dla obu klas potwierdzają, że model równie skutecznie identyfikuje obecność zakoli, jak i ich brak. Tak wysoka symetria wyników, widoczna w poniższej tabeli, jest bezpośrednim efektem zastosowania techniki stratyfikacji danych.

Klasa	Precision	Recall	F1-score	Support
Brak	0,84	0,83	0,83	750
Zakola	0,83	0,84	0,84	750
Łącznie (Accuracy)			0,84	1500

Analiza macierzy pomyłek wskazuje na poprawną klasyfikację 1226 przypadków. Pomyłki nie wynikają z błędnej logiki modelu, lecz z obiektywnych trudności wizualnych, takich jak zasłonięcie linii włosów przez fryzurę lub nakrycia głowy.



Przebieg procesu uczenia również potwierdza wysoką jakość modelu; krzywe dokładności i straty płynnie dążą do optymalnych wartości bez oznak przeuczenia. Wyższa skuteczność na zbiorze walidacyjnym w stosunku do treningowego udowadnia, że mechanizmy augmentacji i warstwy Dropout skutecznie wymusiły na sieci naukę trwałych cech anatomicznych. Ostateczny skok skuteczności z poziomu **67%** (uzyskanego metodami klasycznymi) do **84%** w pełni uzasadnia wybór głębokich sieci neuronowych do realizacji tego zadania.



Weryfikacja wizualna i analiza przypadków granicznych

Ostatni moduł kodu realizuje pełny potok predykcyjny dla sześciu losowych zdjęć ze zbioru testowego. Każdy obraz przechodzi identyczny proces przygotowania jak podczas treningu: skalowanie do wymiarów 128×128

oraz normalizację wartości pikseli do zakresu $[0, 1]$. Model generuje prawdopodobieństwo przynależności do klasy „Zakola”, gdzie wartość powyżej **0.5** jest interpretowana jako obecność cechy.



Na załączonej wizualizacji większość przykładów została sklasyfikowana poprawnie (oznaczone kolorem zielonym). Warto jednak zwrócić uwagę na zróżnicowanie pewności modelu. W przypadkach ewidentnych zakoli (np. zdjęcia w prawym górnym i dolnym rogu), model uzyskuje wyniki rzędu **0.59 – 0.65**, co sugeruje poprawną detekcję krawędzi linii włosów. Jednak gdy linia włosów jest całkowicie zasłonięta przez grzywkę lub nakrycie głowy, model zwraca wynik **Prob: 0.00**. Wynik ten nie oznacza, że model „rozumie”, iż dana osoba nie ma zakoli. Wynika on z faktu, że sieć neuronowa nie odnajduje na obrazie wzorców geometrycznych i krawędziowych, których nauczyła się przypisywać klasie „Zakola”. Jest to klasyczny przykład ograniczenia systemów wizyjnych, które nie posiadają kategorii „nie wiem” lub „obiekt zasłonięty”.

Przedstawiona weryfikacja wizualna dowodzi, że model CNN jest skutecznym narzędziem, dopóki kluczowe cechy anatomiczne są widoczne w kadrze. Przypadki ekstremalnie niskiego prawdopodobieństwa przy zasłoniętym czole stanowią cenny materiał do sekcji **“Ograniczenia modelu”**, wskazując na konieczność stosowania dodatkowych mechanizmów (np. detekcji twarzy en face przed klasyfikacją), aby uniknąć błędnych predykcji wynikających z fryzury lub akcesoriów.

Własne przykłady

Dodatkowo przygotowano sekcję pozwalającą na weryfikację skuteczności sieci neuronowej na zdjęciach spoza zbioru danych CelebA. Moduł ten umożliwia wgranie własnego pliku graficznego w formacie JPG lub PNG bezpośrednio do środowiska obliczeniowego.

Zaimplementowany algorytm automatycznie przeprowadza pełny proces przygotowania zdjęcia: od zmiany przestrzeni barwnej i skalowania do wymaganego formatu **128x128**, po normalizację i dopasowanie wymiarów

tensora wejściowego. Takie podejście pozwala na szybką ocenę, jak model radzi sobie w **warunkach rzeczywistych**, przy różnorodnym oświetleniu i parametrach technicznych współczesnych aparatów.

Wynik predykcji: Wykryto zakola
Prawdopodobieństwo: 0.8365



Podsumowanie

Niniejszy projekt pozwolił na przeprowadzenie pełnej ścieżki badawczej w obszarze widzenia komputerowego – od surowej akwizycji danych, przez klasyczne przetwarzanie sygnałów, aż po zaawansowane modele uczenia głębokiego. Główny cel projektu, polegający na stworzeniu systemu detekcji cofniętej linii włosów o skuteczności powyżej 80%, został w pełni zrealizowany.

Sukces modelu w dużej mierze zależał od poprawnego przygotowania zbioru danych. Zastosowanie **under-samplingu** (zbalansowanie klas 1:1) oraz **próbkowania warstwowego** (stratified sampling) pozwoliło na uzyskanie wiarygodnych metryk i uniknięcie zjawiska „zgadywania” klasy większościowej.

Projekt wykazał przewagę sieci neuronowych nad metodami klasycznymi. Podczas gdy deskryptor **HOG (L4)** osiągnął skuteczność na poziomie ok. **67%**, model **CNN (L5)** podniósł ten wynik do **84,3%**. Potwierdza to postawioną na wstępie hipotezę, że ręcznie projektowane cechy geometryczne są niewystarczające do opisu tak zmiennej cechy, jaką jest linia włosów.

Segmentacja HSV ukazała ograniczenia prostych metod progowania. Wykazano, że analiza pola powierzchni całej twarzy wprowadza zbyt duży błąd statystyczny, co ostatecznie uzasadniło konieczność porzucenia metod geometrycznych na rzecz analizy cech teksturalnych przez sieć neuronową.

Model wykazuje tendencję do błędnej klasyfikacji w przypadku, gdy linia czoła jest zasłonięta przez specyficzne fryzury (grzywki) lub akcesoria (czapki). Sieć neuronowa w takich sytuacjach nie odnajduje znanych jej wzorców „zakoli”, co skutkuje nienaturalnie wysoką pewnością dla klasy „Brak”.

W ramach dalszego rozwoju systemu należałoby rozważyć:

- Wprowadzenie mechanizmu detekcji punktów charakterystycznych twarzy, aby precyzyjnie izolować wyłącznie obszar czoła.
- Rozszerzenie zbioru treningowego o zdjęcia osób w nakryciach głowy oznaczonych nową klasą („Zasłonięte”), co zapobiegłoby „oszukiwaniu” modelu przez proste zasłonięcie czoła.
- Przejście z klasyfikacji binarnej na analizę regresyjną, która pozwoliłaby na precyzyjne określenie procentowego stopnia cofnięcia linii włosów. Wdrożenie modułu porównawczego umożliwiłoby śledzenie zmian u tej samej osoby na przestrzeni miesięcy lub lat, co mogłoby znaleźć zastosowanie w diagnostyce trychologicznej.

Projekt dowiódł, że odpowiednio zaprojektowana architektura sieci konwolucyjnej, wsparta silną augmentacją danych i mechanizmami zapobiegającymi przeuczeniu, jest w stanie z dużą precyzją klasyfikować subtelne atrybuty twarzy. Uzyskane wyniki oraz przeprowadzona analiza błędów stanowią solidną bazę do budowy bardziej złożonych systemów biometrycznych i diagnostycznych.